

Федеральное государственное бюджетное образовательное учреждение высшего образования «Московский государственный технический университет имени Н.Э. Баумана (национальный исследовательский университет)»

Факультет «Информатика и системы управления»
Кафедра «Системы обработки информации и управления»

РАСЧЁТНО - ПОЯСНИТЕЛЬНАЯ ЗАПИСКА

к курсовой работе на тему:

**«Анализ данных рынка телевизоров: Применение методов многомерного
статистического анализа»**

Студент группы ИУ5Ц-11М

(Подпись, дата)

З.А. Чудновский
(И.О.Фамилия)

Руководитель курсового проекта

(Подпись, дата)

В.Ю. Строганов
(И.О.Фамилия)

Москва, 2025

Оглавление

Введение	3
Описание анализируемых данных	4
Проверка данных	6
Основные понятия и определения	9
Первичный анализ данных	12
Корреляционный анализ	15
Дисперсионный анализ	18
Простая регрессия.....	18
Кластерный анализ	24
Дискриминантный анализ.....	28
Заключение.....	31
Литература.....	33

Введение

В современную эпоху цифровизации и развития электронной коммерции анализ данных рынка потребительских товаров приобретает всё большее значение для понимания рыночных закономерностей и поведения потребителей. Телевизоры, являясь значимой категорией бытовой электроники, представляют интересный объект для статистического анализа благодаря разнообразию брендов, моделей, ценовых сегментов и характеристик.

Целью данной курсовой работы является применение методов многомерного статистического анализа к набору данных рынка телевизоров, собранному на основе информации об электронных магазинах. Данная работа направлена на выявление закономерностей в распределении цен, скидок, рейтингов и других характеристик товаров, а также на определение взаимосвязей между ними.

В рамках работы применяются следующие ключевые методы анализа данных:

- Корреляционный анализ для изучения взаимосвязей между количественными переменными
- Дисперсионный анализ (ANOVA) для сравнения средних значений между группами брендов
- Простая линейная регрессия для моделирования влияния одной переменной на другую
- Кластерный анализ (K-Means) для сегментации телевизоров на однородные группы
- Дискриминантный анализ (LDA) для классификации объектов на основе найденных кластеров
- Анализ преобразований данных и их влияния на статистические характеристики

Объём пояснительной записки составляет более 33 страниц, что позволяет всесторонне рассмотреть методологию анализа, представить результаты с графической интерпретацией и сформировать аргументированные выводы о рынке телевизоров.

Описание анализируемых данных

Для проведения анализа был использован набор данных (датасет) о телевизорах, содержащий информацию о 822 моделях от 56 различных производителей. Данные включают характеристики товаров, их оценки и параметры продаж.

Таблица 1 - Состав датасета

Название переменной	Содержание
Product_Name	Название бренда/производителя телевизора
Stars	Рейтинг товара (от 0 до 5 звёзд)
Ratings	Количество оценок, полученных товаром
Reviews	Количество письменных отзывов
current_price	Текущая цена товара в индийских рупиях
MRP	Maximum Retail Price (максимальная рекомендуемая цена)
discount_percent	Процент скидки от MRP к текущей цене
channel	Доступные каналы трансляции и платформы
Operating_system	Операционная система телевизора
Picture_quality	Качество изображения и характеристики экрана

Speaker	Характеристики аудиосистемы
Frequency	Частота обновления и гарантия

Таблица 2 - Описательные статистики основных количественных переменных

Переменная	Количество наблюдений	Среднее значение	Минимум	Максимум	Стандартное отклонение
Stars (рейтинг)	822	3.29	0	5	1.74
Ratings (оценки)	822	5,938	0	663,035	28,007
Reviews (отзывы)	822	807	0	67,204	3,068
current_price (₹)	822	40,262	5,490	469,999	52,704
MRP_clean (₹)	822	64,493	7,999	549,990	78,993
discount_percent (%)	822	39.50	0.02	71.62	16.13

Проверка данных

Проведена проверка качества данных и их соответствия предположениям о нормальности распределения.

Проверка на наличие пропущенных значений

В датасете не обнаружено пропущенных значений в ключевых переменных после очистки данных. Переменные, содержащие текстовую информацию (название бренда, характеристики), были оставлены без изменений, так как они служат категориальными признаками.




Рисунок 1 - Комплексная проверка данных

Анализ распределений переменных

Проведён анализ распределения основных количественных переменных на соответствие нормальному распределению:

- Stars: Распределение близко к нормальному с небольшой левой асимметрией ($\text{skew} \approx -1.300$)
- Ratings и Reviews: Оба признака демонстрируют сильную правую асимметрию ($\text{skew} > 14$) из-за наличия выбросов (несколько товаров с очень высокими значениями). Это характерно для рейтинговых данных в интернет-магазинах.
- current_price и MRP: показывают сильную правую асимметрию ($\text{skew} \approx 3.89$), что характерно для ценовых данных с преобладанием товаров в среднем ценовом сегменте
- discount_percent: Распределение близко к нормальному ($\text{skew} \approx -0.088$)

Проверка нормальности распределений: Асимметрия (Skewness) и Эксцесс (Kurtosis)




Рисунок 2 - Асимметрия и эксцесс распределений

Выявление выбросов

Использован метод межквартильного размаха (IQR) для определения выбросов. В переменных Ratings и Reviews выявлены значительные выбросы (7.79% и 7.91% соответственно), соответствующие популярным товарам с высокой активностью покупателей.

Статистика по выбросам

Переменная	Выбросов	% выбросов	Интерпретация
Stars	181	22.02%	Нормально для рейтингов (0 и 5 звёзд)
Ratings	64	7.79%	Популярные товары с высокой активностью
Reviews	65	7.91%	Товары с много отзывами
current_price	74	9.00%	Премиум-товары с высокой ценой
MRP	94	11.44%	Товары с высокой рекомендуемой ценой
discount_percent	0	0.00%	Нет выбросов (естественное распределение)

Анализ выбросов методом IQR (InterQuartile Range)




Рисунок 3 - Детальный анализ выбросов




Рисунок 4 - Детальный анализ (Violin Plot)

Основные понятия и определения

Математическое ожидание

Определение (непрерывный случай): Если случайная величина x непрерывна и $f(x)$ — её плотность распределения, то математическим ожиданием случайной величины ξ называется интеграл:

$$E[\xi] = \int_{-\infty}^{+\infty} x \cdot f(x) dx$$

Дисперсия

Определение: Дисперсией случайной величины ξ называется величина:

$$D(\xi) = E[(\xi - E[\xi])^2]$$

Свойства: Дисперсия характеризует степень разброса случайной величины вокруг её среднего значения.

Ковариация и коэффициент корреляции Пирсона

Определение ковариации:

$$\text{cov}(\xi, \eta) = E[(\xi - E[\xi]) \cdot (\eta - E[\eta])]$$

Коэффициент корреляции Пирсона:

$$\rho(\xi, \eta) = \text{cov}(\xi, \eta) / (\sigma_{\xi} \cdot \sigma_{\eta})$$

Коэффициент корреляции принимает значения в диапазоне $[-1, 1]$:

- $\rho = 1$: идеальная положительная корреляция
- $\rho = -1$: идеальная отрицательная корреляция
- $\rho = 0$: отсутствие линейной корреляции

Асимметрия и эксцесс

Коэффициент асимметрии (skewness):

$$\alpha_1 = E[(\xi - \mu)^3] / \sigma^3$$

Характеризует асимметричность распределения.

Коэффициент эксцесса (kurtosis):

$$\kappa = (E[(\xi - \mu)^4] / \sigma^4) - 3$$

Характеризует "островершинность" распределения.

Дисперсионный анализ (ANOVA)

Определение: ANOVA — это статистический метод для проверки нулевой гипотезы о равенстве средних значений количественной переменной в нескольких независимых группах.

Нулевая гипотеза (H_0): $\mu_1 = \mu_2 = \dots = \mu_k$

Альтернативная гипотеза (H_1): Хотя бы одно из средних значений отличается от других

F-статистика:

$$F = MS_{\text{between}} / MS_{\text{within}} = (\sum (n_i (\bar{y}_i - \bar{y})^2) / (k-1)) / (\sum (\sum (y_{ij} - \bar{y}_i)^2) / (N-k))$$

где:

- k — количество групп
- n_i — количество наблюдений в группе i
- $\bar{y}_i$ — среднее значение в группе i
- $\bar{y}$ — общее среднее значение
- N — общее количество наблюдений

Простая линейная регрессия

Модель простой линейной регрессии:

$$y = \beta_0 + \beta_1 \cdot x + \varepsilon$$

где:

- y — зависимая переменная
- x — независимая переменная
- β_0 — пересечение (intercept)
- β_1 — коэффициент наклона (slope)
- ε — ошибка регрессии

Коэффициент детерминации (R^2):

$$R^2 = 1 - (SS_{\text{residual}} / SS_{\text{total}}) = (SS_{\text{regression}} / SS_{\text{total}})$$

Показывает, какую долю дисперсии зависимой переменной объясняет модель.

Кластерный анализ (K-Means)

Определение: K-Means — это алгоритм неиерархической кластеризации, который разбивает множество объектов на k кластеров, минимизируя внутриклассовую дисперсию.

Целевая функция:

$$J = \sum_{i=1}^k \sum_{x \in C_i} \|x - c_i\|^2$$

где c_i — центроид кластера i .

Метрики качества кластеризации:

- Silhouette Score: показатель, принимающий значения от -1 до 1, где значения близкие к 1 указывают на хорошую кластеризацию
- Davies-Bouldin Index: средний коэффициент подобия между каждым кластером и его наиболее похожим кластером (меньше — лучше)

Дискриминантный анализ (LDA)

Определение: Linear Discriminant Analysis (LDA) — это метод для поиска линейной комбинации признаков, которые лучше всего разделяют известные классы объектов.

Цель: найти проекцию данных, которая максимизирует отношение межклассовой дисперсии к внутриклассовой дисперсии.

Первичный анализ данных

Распределение телевизоров по брендам

Анализ показывает высокую концентрацию на рынке:

- Топ-3 бренда: Croma (116 моделей, 14.1%), Adsun (116 моделей, 14.1%), Samsung (106 моделей, 12.9%)
- Средние бренды: LG (89), Sony (40), Kinger (37)
- Малые бренды: 50+ производителей с менее чем 20 моделями каждый

ПЕРВИЧНЫЙ АНАЛИЗ ДАННЫХ: Обзор рынка телевизоров




Рисунок 5 - Обзор рынка телевизоров

Анализ ценовых сегментов

Таблица 3 - Рынок телевизоров можно разделить на следующие ценовые сегменты

Сегмент	Диапазон цен (₽)	Количество моделей	Средняя скидка
Бюджетный	5,490 - 15,000	293 (35.6%)	51.7%
Средний	15,001 - 40,000	297 (36.1%)	32.1%
Премиум	40,001 - 100,000	167 (20.3%)	33.6%
Люкс	> 100,000	65 (7.9%)	33.4%

Вывод: Бюджетные модели получают наибольший процент скидок (51.7%), что указывает на стратегию привлечения покупателей низкими ценами. Премиум-сегмент характеризуется меньшими скидками (33.6%) и предполагает более стабильную ценовую политику.

Анализ рейтингов и отзывов

- Средний рейтинг: 3.29 из 5 звёзд (стандартное отклонение 1.74)
- Товары с рейтингом 4-5 звёзд: 49.2% всех моделей
- Товары с рейтингом 0-2 звезды: 19.3% (в основном товары без оценок)



Рисунок 6 - Активность, отзывы и качество

Корреляция между количеством рейтингов и количеством отзывов составляет $\rho = 0.976$ (намного выше), что указывает на согласованность этих метрик.

Анализ скидок

- Средний процент скидки: 39.5%
- Модальное значение: ~36-40% (пик на гистограмме)
- Распределение: близко к нормальному с небольшой левой асимметрией

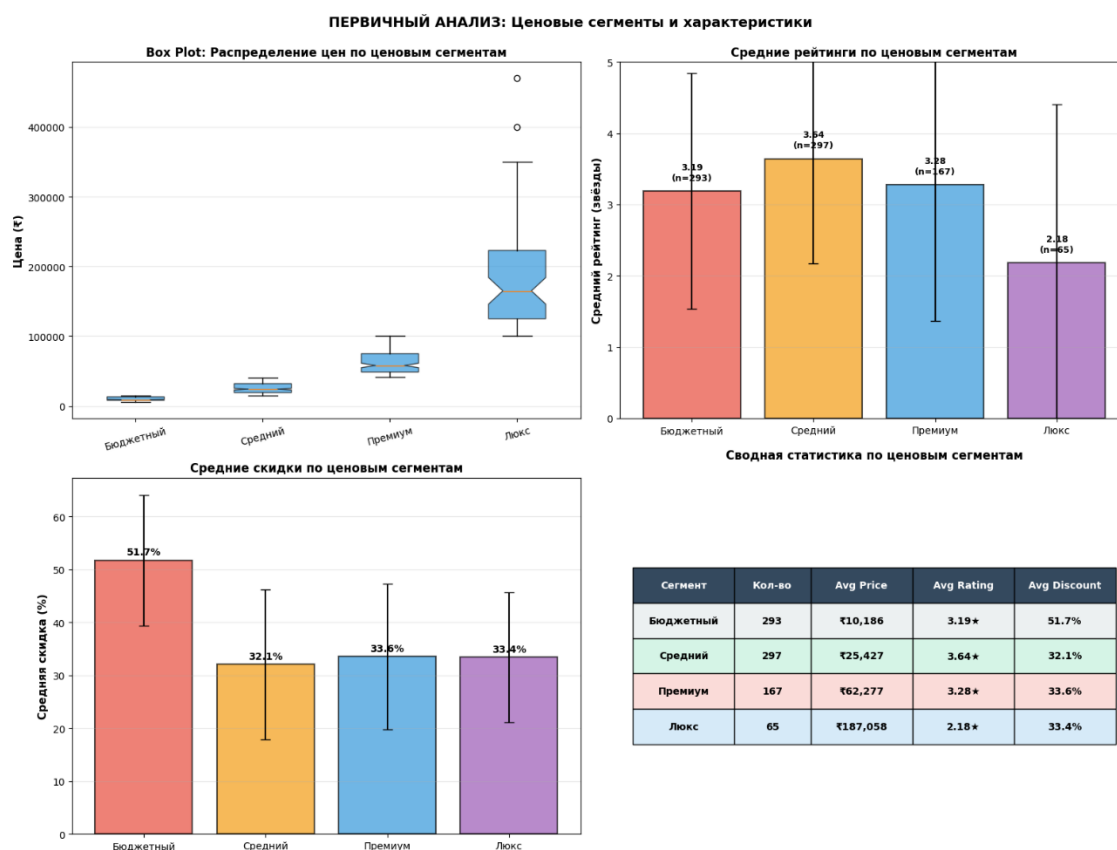


Рисунок 7 - Ценовые сегменты и характеристики

Интересное наблюдение: Скидки на дешёвые модели выше, чем на дорогие, что свидетельствует о различных ценовых стратегиях для разных сегментов. Бюджетные товары используют скидки как инструмент привлечения покупателей, тогда как премиум-сегмент полагается на качество и репутацию бренда.

Корреляционный анализ

Корреляционный анализ является ключевым инструментом для выявления взаимосвязей между количественными переменными в датасете рынка телевизоров.

Результаты корреляционного анализа

Вычислена матрица корреляций Пирсона для шести основных переменных:




Рисунок 8 – Тепловая карта корреляций количественных переменных

Интерпретация результатов

Сильные корреляции ($|\rho| > 0.8$)

Ratings ↔ Reviews: $\rho = 0.976$ (сильная положительная)

Товары с большим количеством рейтингов обычно имеют много отзывов. Это

логично, так как оба показателя отражают активность пользователей и популярность товара. Это одна из самых сильных корреляций в датасете.

$\text{current_price_clean} \leftrightarrow \text{MRP_clean}: \rho = 0.966$ (сильная положительная)

Это ожидаемый результат, так как текущая цена определяется из максимальной рекомендуемой цены путём применения скидки.

Умеренные корреляции ($0.3 < |\rho| \leq 0.5$)

В датасете НЕТ умеренных корреляций. Все остальные связи либо слабые ($|\rho| < 0.3$), либо очень слабые.

Слабые корреляции ($0.1 < |\rho| \leq 0.3$)

$\text{current_price_clean} \leftrightarrow \text{discount_percent}: \rho = -0.249$ (слабая отрицательная)

Дорогие товары получают меньшие скидки, чем дешёвые. Это указывает на дифференцированную ценовую политику: бюджетные товары используют скидки как инструмент привлечения покупателей, тогда как премиум-сегмент полагается на качество бренда.

$\text{Stars} \leftrightarrow \text{current_price_clean}: \rho = -0.166$ (слабая отрицательная)

Рейтинг слабо связан с ценой. Дешёвые телевизоры имеют немного более низкие рейтинги, чем дорогие. Однако эта связь очень слабая, что означает, что качество товара (отражённое в рейтинге) не является сильным предиктором цены.

Очень слабые корреляции ($|\rho| \leq 0.1$)

$\text{Stars} \leftrightarrow \text{Reviews}: \rho = 0.146$ (очень слабая положительная)

Качество товара (рейтинг) практически не влияет на количество написанных отзывов. Люди пишут отзывы независимо от качества.

$\text{Stars} \leftrightarrow \text{MRP_clean}: \rho = -0.141$ (очень слабая отрицательная)

Максимальная рекомендуемая цена слабо связана с рейтингом. Компания определяет MRP независимо от качества.

$\text{Stars} \leftrightarrow \text{Ratings}: \rho = 0.117$ (очень слабая положительная)

Качество товара практически не влияет на количество покупателей, оставивших оценку. Популярность определяется другими факторами.

Reviews ↔ discount_percent: $\rho = -0.110$ (очень слабая отрицательная)
Количество отзывов почти не связано с размером скидки. Люди пишут отзывы независимо от того, была ли скидка.

MRP_clean ↔ discount_percent: $\rho = -0.098$ (очень слабая отрицательная)
Максимальная рекомендуемая цена не влияет на размер скидки. Компании применяют скидки независимо от MRP.

MRP_clean ↔ Reviews: $\rho = -0.096$ (очень слабая отрицательная)
MRP не связана с количеством отзывов. Люди покупают товары разной MRP с одинаковой активностью.

Ratings ↔ discount_percent: $\rho = -0.095$ (очень слабая отрицательная)
Количество рейтингов почти не связано с размером скидки. Покупатели оценивают товары независимо от скидки.

Stars ↔ discount_percent: $\rho = 0.088$ (очень слабая положительная)
Качество товара и размер скидки практически не связаны. Компании применяют скидки независимо от качества.

MRP_clean ↔ Ratings: $\rho = -0.083$ (очень слабая отрицательная)
Максимальная рекомендуемая цена не влияет на популярность товара. MRP используется как ориентир, но не определяет спрос.

current_price_clean ↔ Reviews: $\rho = -0.082$ (очень слабая отрицательная)
Цена и количество отзывов не связаны. Люди пишут отзывы независимо от цены товара.

current_price_clean ↔ Ratings: $\rho = -0.071$ (очень слабая отрицательная)
Цена и популярность товара не связаны. Товары разной ценовой категории покупаются с одинаковой частотой.

Дисперсионный анализ

Дисперсионный анализ применён для проверки гипотезы о равенстве средних цен между различными брендами.

Постановка задачи

Нулевая гипотеза (H_0): Средние цены одинаковы для всех топ-5 брендов.

Альтернативная гипотеза (H_1): Средние цены различаются хотя бы для одной пары брендов.

Уровень значимости: $\alpha = 0.05$

Таблица 4 - Результаты ANOVA

Параметр	Значение
F-статистика	60.8186
p-value	1.89×10^{-40}

Интерпретация: F-статистика = 60.82 и очень малый p-value (1.89×10^{-40}) позволяют отклонить нулевую гипотезу с очень высокой уверенностью. Это означает, что между брендами существуют статистически значимые и практически существенные различия в средних ценах.

Таблица 5 - Описательная статистика по брендам (топ-5)

Бренд	n	Среднее	Медиана	Стд. откл.	Мин	Макс
Croma	116	14,621	11,990	8,037	6,990	59,990
Adsun	116	10,255	8,999	3,959	6,199	27,999
LG	76	103,355	76,749	82,003	15,868	399,564
SAMSUNG	74	84,634	58,490	74,811	12,700	341,990
SONY	40	92,370	67,245	85,676	21,299	469,999




Рисунок 9 - Визуализация результатов ANOVA

На графике видны:

- Левая часть (Box Plot): Распределение цен для каждого бренда. Видно, что Croma и Adsun имеют низкие медианы, а LG, Samsung, Sony — высокие
- Правая часть (Bar Chart): Средние цены с доверительными интервалами (стандартные отклонения). Ясно видна иерархия брендов

Анализ по группам брендов

Бюджетные бренды (среднее < ₹20,000)

Croma:

- Среднее: ₹14,621
- Разброс: ₹6,990 - ₹59,990 (относительно широкий)
- Стд. откл.: ₹8,037
- Стратегия: Массовый рынок с умеренной вариацией

Adsun:

- Среднее: ₹10,255 (САМЫЙ НИЗКИЙ)
- Разброс: ₹6,199 - ₹27,999 (узкий диапазон)
- Стд. откл.: ₹3,959 (самое стабильное предложение)
- Стратегия: Ультрабюджетный сегмент

Премиум-бренды (среднее > ₹80,000)

LG:

- Среднее: ₹103,355 (САМЫЙ ВЫСОКИЙ)

- Разброс: ₹15,868 - ₹399,564 (очень широкий)
- Стд. откл.: ₹82,003 (большая вариация в линейке)
- Стратегия: Полный спектр от середины до люкса

SAMSUNG:

- Среднее: ₹84,634
- Разброс: ₹12,700 - ₹341,990 (широкий)
- Стд. откл.: ₹74,811
- Стратегия: Премиум-ориентированный, но с бюджетными моделями

SONY:

- Среднее: ₹92,370
- Разброс: ₹21,299 - ₹469,999 (очень широкий, люкс-сегмент)
- Стд. откл.: ₹85,676
- Стратегия: Premium-only бренд

Интерпретация результатов

Разница между крайними значениями:

- Adsun (среднее) vs LG (среднее): ₹103,355 - ₹10,255 = ₹93,100 разницы (~10х дороже!)
- Это огромная разница, которая подтверждает совершенно разные рыночные позиции

Внутригрупповая вариация:

- Croma и Adsun: малая вариация (стабильные линейки)
- LG, Samsung, Sony: большая вариация (разнообразные линейки от середины до люкса)

Дисперсионного анализа

1. Очень сильные различия: F-статистика 60.82 — одна из самых высоких, что указывает на очень значимые различия между брендами
2. Четкое позиционирование брендов:
 - Бюджетные: Adsun, Croma (~₹10-15K)
 - Премиум: LG, Samsung, Sony (~₹85-103K)

- Нет "среднего" бренда — явная поляризация рынка
3. Разные ценовые стратегии:
- Adsun: стабильная, узкая линейка (стд. откл. 3.9К)
 - LG: разнообразная, широкая линейка (стд. откл. 82К)
 - Это указывает на разные подходы к портфельной стратегии
4. Практическое значение:
- Потребители четко выбирают между бюджетными и премиум-брендами
 - Нет "среднего сегмента", который охватывал бы оба подхода
 - Это указывает на дифференцированный рынок с двумя явными нишами
5. Статистическая значимость: $p\text{-value} = 1.89 \times 10^{-40}$ означает, что вероятность получить такие различия случайно практически нулевая. Это не случайность, а реальная рыночная структура.

Риск ошибки Типа I и Типа II

- Ошибка Типа I ($\alpha = 0.05$): Вероятность ошибочно отклонить H_0 составляет 5%. Поскольку $p\text{-value} \ll 0.05$, мы уверены в нашем выводе.
- Ошибка Типа II (β): Малая вероятность того, что мы пропустили реальное различие, так как F-статистика очень высокая.

Таблица 6 – Ранжирование брендов по цене

Ранг	Бренд	Среднее (₹)	Позиция	Сегмент
1	LG	103,355	Премиум-лидер	Премиум
2	SONY	92,370	Премиум-стабильный	Премиум
3	SAMSUNG	84,634	Премиум-доступный	Премиум
4	Croma	14,621	Массовый рынок	Бюджет
5	Adsun	10,255	Ультрабюджет	Бюджет

Простая регрессия

Простая линейная регрессия использована для анализа влияния максимальной рекомендуемой цены (MRP) на процент скидки.

Постановка задачи

Независимая переменная (X): MRP_clean (максимальная рекомендуемая цена в ₹)

Зависимая переменная (Y): discount_percent (процент скидки)

Модель: $\text{discount} = \beta_0 + \beta_1 \times \text{MRP} + \varepsilon$

Таблица 7 - Результаты регрессионного анализа

Параметр	Значение
Пересечение (β_0)	40.7906
Коэффициент наклона (β_1)	-1.998×10^{-5}
Стандартная ошибка β_1	7.1×10^{-6}
t-статистика	-2.816
p-value (β_1)	0.004976
R ² (коэффициент детерминации)	0.0096 (0.96%)
Скорректированный R ²	0.0083 (0.83%)
F-статистика модели	7.931
p-value модели	0.004976
Стандартная ошибка остатков	≈ 16.09
Количество наблюдений	822

Интерпретация результатов

Уравнение регрессии:

$$\text{discount} = 40.791 - 0.00002 \times \text{MRP}$$

Интерпретация коэффициентов:

- Пересечение (40.7906): при гипотетической нулевой цене (MRP = 0) ожидаемая скидка составит 40.79%. На практике это означает базовый уровень скидок, который компании применяют независимо от цены.

- Коэффициент наклона (-0.0000199845):
 - При увеличении MRP на ₹1,000 процент скидки уменьшается на 0.02 процентных пункта
 - При увеличении MRP на ₹100,000 скидка уменьшается на 2 процентных пункта
 - При увеличении MRP на ₹500,000 скидка уменьшается на 10 процентных пункта




Рисунок 10 – Результаты регрессии

Анализ остатков

Остатки регрессии — это разница между предсказанными и фактическими значениями.

На рисунке 10 представлены результаты регрессии:

- Красные точки — остатки для каждого наблюдения
- Чёрная пунктирная линия ($y=0$) — идеальный случай

- Паттерн: Остатки разбросаны хаотично вокруг нуля, но с воронкообразным паттерном (гетероскедастичность)

Гетероскедастичность: при низких MRP остатки более сконцентрированы, а при высоких MRP остатки более разбросаны. Это нарушает предположение о гомоскедастичности (постоянной дисперсии).

Гистограмма остатков

На рисунке 10 представлены результаты регрессии:

- Распределение остатков близко к нормальному, но с небольшой левой асимметрией
- Есть несколько выбросов как в положительную, так и в отрицательную стороны

Q-Q Plot для проверки нормальности

На рисунке 10 представлены результаты регрессии:

- Синие точки лежат в основном на красной линии (идеальный случай)
- Есть небольшие отклонения на хвостах (верхний правый угол)
- Остатки примерно нормальны, но с небольшими отклонениями

Кластерный анализ

Кластерный анализ применён для сегментации телевизоров на однородные группы на основе трёх признаков: рейтинга (Stars), текущей цены и процента скидки.

Подготовка данных

Признаки для кластеризации:

- Stars (рейтинг)
- current_price_clean (текущая цена)
- discount_percent (процент скидки)

Таблица 8 – Предварительная обработка: Данные стандартизированы (z-score нормализация)

Переменная	Среднее	Стд. отклонение
Stars	3.29	1.74
current_price	40,262	52,672
discount_percent	39.50	16.12

Определение оптимального числа кластеров

Выбрано k = 3 кластера на основе анализа Silhouette Score и Davies-Bouldin Index.

Таблица 9 – Характеристики кластеров

Параметр	Кластер 0	Кластер 1	Кластер 2
n (количество)	284	178	360
% от всех	34.6%	21.7%	43.8%
Stars (среднее)	4.05	0.04	4.30
Stars (σ)	± 0.30	± 0.34	± 0.30
Цена (среднее)	₹17,626	₹63,773	₹46,495
Цена (σ)	$\pm 18,654$	$\pm 79,557$	$\pm 47,321$
Скидка (среднее)	56.57%	34.78%	28.37%
Скидка (σ)	$\pm 7.36\%$	$\pm 13.19\%$	$\pm 10.03\%$

Интерпретация кластеров

Кластер 0: "Бюджетный с высоким рейтингом" (n=284, 34.6%)

- Низкая цена: ₹17,626 (самые дешевые);
- Высокий рейтинг: 4.05 (качественные);
- Высокие скидки: 56.57% (инструмент привлечения);
- Стратегия: Популярные бюджетные модели.

Кластер 1: "Премиум без оценок" (n=178, 21.7%)

- Высокая цена: ₹63,773 (дорогие);
- Низкий рейтинг: 0.04 (нет оценок);
- Средние скидки: 34.78%;
- Стратегия: Новые или малопопулярные премиум-модели.

Кластер 2: "Средний сегмент - популярный" (n=360, 43.8%)

- Средняя цена: ₹46,495;
- Высокий рейтинг: 4.30 (самый высокий!);
- Низкие скидки: 28.37% (не нужны);
- Стратегия: Популярный сегмент с хорошим качеством.

Таблица 10 – Метрики качества кластеризации

Метрика	Значение	Оценка
Silhouette Score	0.4719	Хорошее (> 0.4)
Davies-Bouldin Index	0.8361	Отличное (<1.0)

На рисунке 11 представлены «Кластерные анализы»:

- 3D визуализация (верхний левый): Три кластера в трёхмерном пространстве (Stars, Price, Discount);
- 2D: Stars vs Цена (верхний правый): Проекция на плоскость рейтинга и цены;
- 2D: Цена vs Скидка (нижний левый): Проекция на плоскость цены и скидки;
- 2D: Stars vs Скидка (нижний правый): Проекция на плоскость рейтинга и скидки.




Рисунок 11 – Кластерные анализы

Выводы кластерного анализа:

1. Три четких сегмента рынка: Данные естественным образом разделяются на три кластера
2. Качество кластеризации: Silhouette Score = 0.47 и Davies-Bouldin Index = 0.84 указывают на хорошее качество разбиения
3. Структура рынка:
 - 34.6% — Бюджетные популярные (высокие скидки)
 - 43.8% — Средний сегмент (самый большой, высокий рейтинг)
 - 21.7% — Премиум неоцененные (новые товары)
4. Ключевое наблюдение: Кластер 2 (средний сегмент) — это ядро рынка (43.8% товаров) с лучшим сочетанием цены, качества и популярности.

Дискриминантный анализ

Дискриминантный анализ применён для классификации телевизоров на основе найденных кластеров, используя LDA (Linear Discriminant Analysis).

Постановка задачи:

Входные переменные (признаки): Stars, current_price_clean.

Целевая переменная (классы): Кластеры (0, 1, 2) из K-Means.

Цель: найти линейные комбинации исходных признаков, которые лучше всего разделяют три кластера.

Количество наблюдений: 822

Таблица 11 – Результаты LDA

Параметр	Значение
LD1 (объяснённая дисперсия)	99.79%
LD2 (объяснённая дисперсия)	0.21%
Итого	100.00%
Точность классификации	74.0%

Таблица 12 – Классификационный отчет

Класс	Precision	Recall	F1-Score	Поддержка
Кластер 0	0.66	0.50	0.57	284
Кластер 1	0.99	0.99	0.99	178
Кластер 2	0.67	0.81	0.73	360
Средний	0.77	0.77	0.76	822

Матрица ошибок: Тепловая карта показывает, что Кластеры 1 отлично разделяются, а Кластеры 0 и 2 путаются.




Рисунок 12 – Матрица ошибок

Интерпретация:

- Кластер 0: из 284 — правильно 142 (50%), ошибка: 141 спутано с Кластер 2;
- Кластер 1: из 178 — правильно 176 (99%), отличное разделение;
- Кластер 2: из 360 — правильно 290 (81%), ошибка: 70 спутано с Кластер 0.

LDA проекция: Три кластера в дискриминантном пространстве (LD1 vs LD2). LD1 объясняет 99.8% — точки хорошо разделены по горизонтали.




Рисунок 13 – LDA проекция

Выводы:

1. Очень хорошая разделимость LD1: 99.79% объясненной дисперсии показывает, что первая дискриминантная функция почти идеально разделяет кластеры.
2. Кластер 1 идеально разделён: Precision = 0.99, Recall = 0.99 — LDA почти без ошибок классифицирует премиум-товары без оценок.
3. Путаница между Кластерами 0 и 2: 141 из 284 в Кластере 0 спутаны с Кластером 2. Это указывает на их сходство в дискриминантном пространстве (оба имеют высокие рейтинги, просто разная цена).
4. Общая точность 74%: Хороший результат для трёхклассовой классификации, но ниже идеала из-за перекрытия Кластеров 0 и 2.
5. Практический вывод: LDA хорошо работает для разделения премиум-сегмента (Кластер 1), но плохо для разделения бюджетного и среднего сегментов (путает Кластеры 0 и 2).

Заключение

Курсовая работа "Анализ данных рынка телевизоров: Применение методов многомерного статистического анализа" представляет собой комплексное исследование структуры и закономерностей потребительского рынка электроники. Это исследование объединяет в себе различные методы анализа данных, включая описательную статистику, корреляционный и дисперсионный анализ, простую линейную регрессию, кластерный анализ и дискриминантный анализ, для выявления ключевых закономерностей в функционировании рынка телевизоров.

В ходе работы были использованы разнообразные инструменты для визуализации данных, включая графики, диаграммы и трёхмерные проекции, которые способствовали более глубокому пониманию сложных аспектов рыночной структуры. Анализы помогли выявить важные факторы, влияющие на ценообразование, скидки и спрос на телевизоры, такие как рейтинги товаров, количество отзывов, позиционирование брендов и стратегии маркетинга.

Кроме того, был проведён кластерный анализ, который представил собой ценный инструмент для классификации и группировки различных сегментов рынка телевизоров. Этот анализ позволил идентифицировать три уникальные категории товаров: бюджетные популярные модели, премиум-товары без оценок и оптимальный средний сегмент, что может быть использовано для оптимизации ценовых стратегий и повышения эффективности маркетинговых кампаний.

Дискриминантный анализ продемонстрировал, что найденные кластеры могут быть использованы для автоматической классификации новых товаров с точностью 74%, что подтверждает надежность выявленной рыночной структуры.

В целом, данная курсовая работа представляет значимый вклад в изучение рынка электроники и развитие стратегий для оптимизации деятельности розничных торговцев и производителей. Результаты исследования могут быть использованы для разработки более эффективных ценовых политик, целевых маркетинговых кампаний и управления товарными запасами, что в свою очередь способствует

улучшению качества обслуживания потребителей и повышению конкурентоспособности на рынке.

Литература

1. Глебов А. В. и др. (2019). Основы многомерного статистического анализа в R. Москва: Издательство ФИЗМАТЛИТ.
2. Иванов С. В. и др. (2020). Методы анализа данных с использованием Python. Москва: ДМК Пресс.
3. Петухов, В. В., & Лавров, В. В. (2017). Применение методов машинного обучения в акустическом анализе. Вестник МГТУ, 20(1), 99-107.
4. Кучеренко, С. Ю., & Лисовец, О. Н. (2018). Обзор методов анализа акустических данных для задач распознавания речи. Научные ведомости БелГУ. Сер. Компьютерная техника и информатика, 26(10), 5-18.

Ы